Basic of Data Analytics

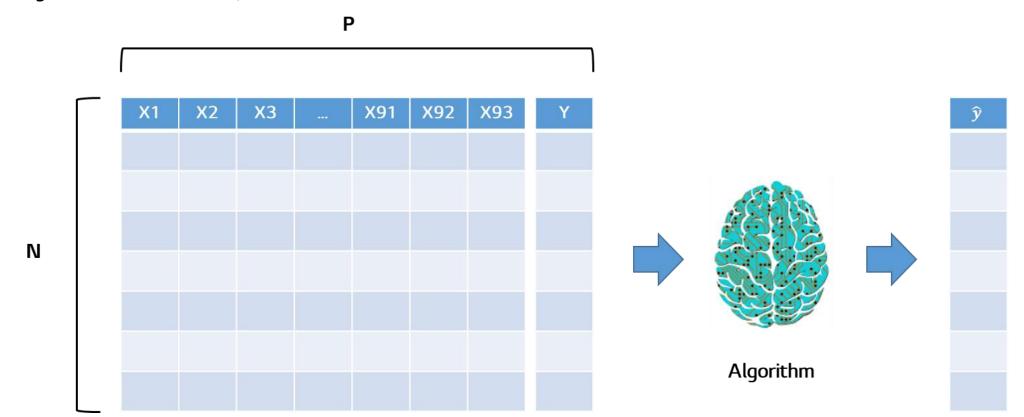
Data Scientist 안건이 Bias vs Variance

Overfitting vs Underfitting

K-fold Cross Validation

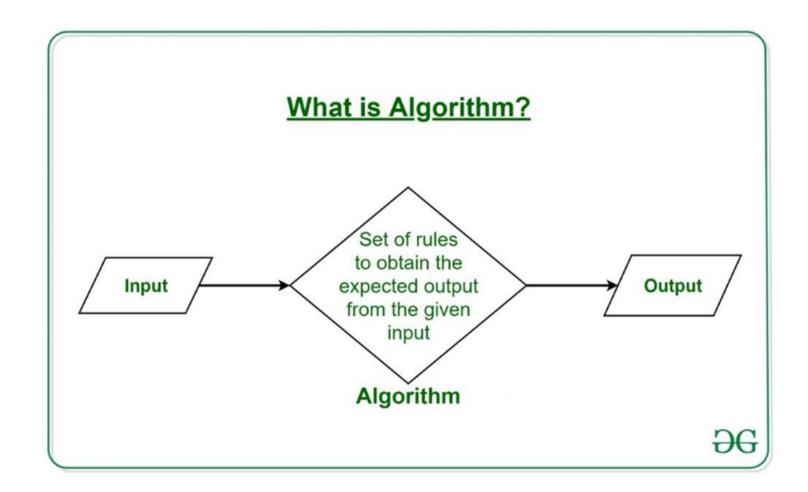
Loss Function (Gradient Descent)

- 정형 데이터 : N x P, Table 데이터
- X: Variables, Features, Columns, 독립변수, 설명변수
 - Numerical : 연속적인 변수 (2는 1보다 크다, 변수에 대/소가 의미 있음)
 - Categorical : 이분적인 변수 (2는 1과 다름, 변수에 대/소가 의미 없음)
- Y: Labels, 종속변수
 - Numerical : Regression, 회귀모형
 - Categorical : Classification, 분류모형

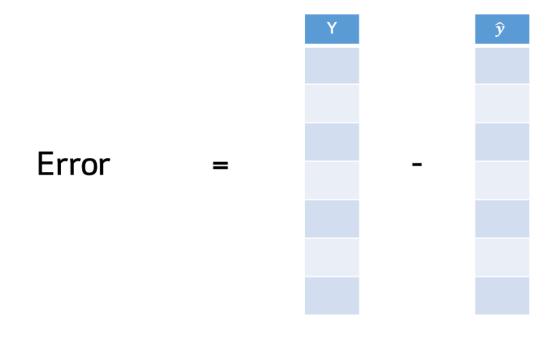


- Algorithm = Input → Process → Output
 - Model
- 좋은 알고리즘의 기준은 ?
 - Error가 낮은 Algorithm



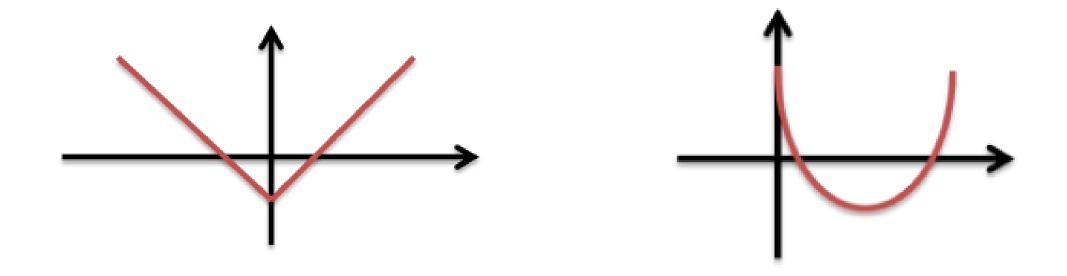


- Error가 낮은 Algorithm (Model)이 데이터의 패턴을 잘 학습한 것
- Square의 이유

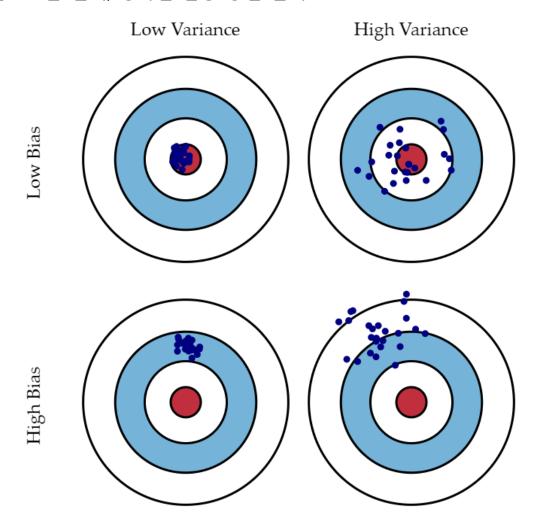


Error =
$$\sum (\hat{y} - y)^2$$

- Error가 낮은 Algorithm (Model)이 데이터의 패턴을 잘 학습한 것
- Square의 이유



- Error(X) = Noise(X) + Bias(X) + Variance(X)
 - Noise(X): 데이터가 본질적으로 품고 있는 한계점
 - 극복 방법 : 정확한 Data Preprocessing
 - Bias(X) 와 Variance(X) : 모델에 따라 변하는 한계점
 - 극복 방법: 상황에 맞는 알고리즘 선택, 정확한 검증 방법 선택



- Bias(X)
 - <u>추정 값</u>의 평균과 <u>참 값</u>들 간의 차이
- Variance(X)
 - 추정 값의 평균과 추정 값들 간의 차이
- Bias는 참 값과 추정 값의 거리를 의미, Variance는 추정 값들의 흩어진 정도
 - Variance는 loss를 의미하지만, 참 값과는 관계없이 추정 값들의 흩어진 정도만을 의미함

$$\begin{split} \operatorname{MSE}(\hat{\theta}) &= \operatorname{E}_{\theta} \Big[(\hat{\theta} - \theta)^2 \Big] \\ &= \operatorname{E}_{\theta} \Big[(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] + \operatorname{E}_{\theta}[\hat{\theta}] - \theta)^2 \Big] \\ &= \operatorname{E}_{\theta} \Big[(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}])^2 + 2 \left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right) \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right) + \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right)^2 \Big] \\ &= \operatorname{E}_{\theta} \Big[\left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right)^2 \Big] + \operatorname{E}_{\theta} \Big[2 \left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right) \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right) \Big] + \operatorname{E}_{\theta} \Big[\left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right)^2 \Big] \\ &= \operatorname{E}_{\theta} \Big[\left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right)^2 \Big] + 2 \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right) \operatorname{E}_{\theta} \Big[\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \Big] + \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right)^2 \\ &= \operatorname{E}_{\theta} \Big[\left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right)^2 \Big] + 2 \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right) \left(\operatorname{E}_{\theta}[\hat{\theta}] - \operatorname{E}_{\theta}[\hat{\theta}] \right) + \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right)^2 \\ &= \operatorname{E}_{\theta} \Big[\left(\hat{\theta} - \operatorname{E}_{\theta}[\hat{\theta}] \right)^2 \Big] + \left(\operatorname{E}_{\theta}[\hat{\theta}] - \theta \right)^2 \\ &= \operatorname{Var}_{\theta}(\hat{\theta}) + \operatorname{Bias}_{\theta}(\hat{\theta}, \theta)^2 \\ \text{Alternatively, we have} \end{split}$$

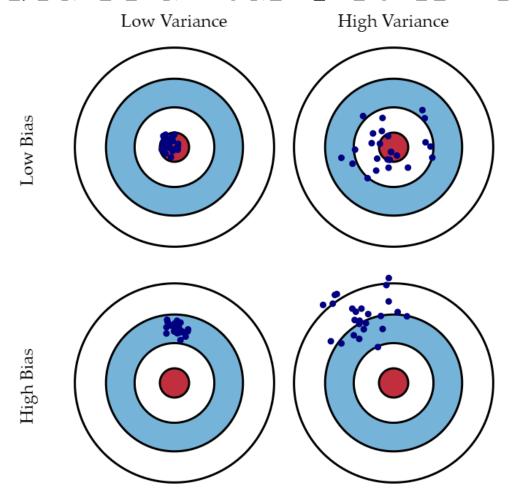
$$\mathbb{E}(\theta - \hat{\theta})^{2} = \mathbb{E}(\hat{\theta}^{2}) + \mathbb{E}(\theta^{2}) - 2\theta\mathbb{E}(\hat{\theta})$$

$$= \operatorname{Var}(\hat{\theta}) + (\mathbb{E}\hat{\theta})^{2} + \theta^{2} - 2\theta\mathbb{E}(\hat{\theta})$$

$$= \operatorname{Var}(\hat{\theta}) + (\mathbb{E}\hat{\theta} - \theta)^{2}$$

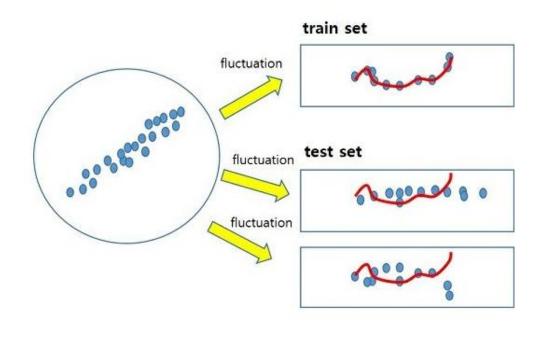
$$= \operatorname{Var}(\hat{\theta}) + \operatorname{Bias}^{2}(\hat{\theta})$$

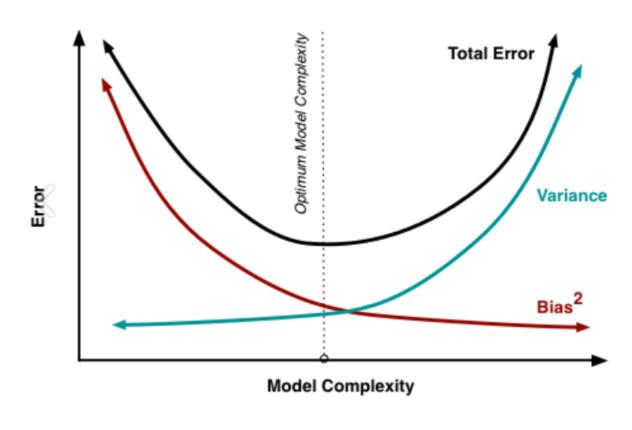
- Bias(X)
 - <u>추정 값</u>의 평균과 <u>참 값</u>들 간의 차이
- Variance(X)
 - <u>추정 값</u>의 평균과 <u>추정 값</u>들 간의 차이
- Bias는 참 값과 추정 값의 거리를 의미, Variance는 추정 값들의 흩어진 정도
 - Variance는 loss를 의미하지만, 참 값과는 관계없이 추정 값들의 흩어진 정도만을 의미함



- Train Data vs Test Data
 - Bias와 Variance의 Trade-Off 관계

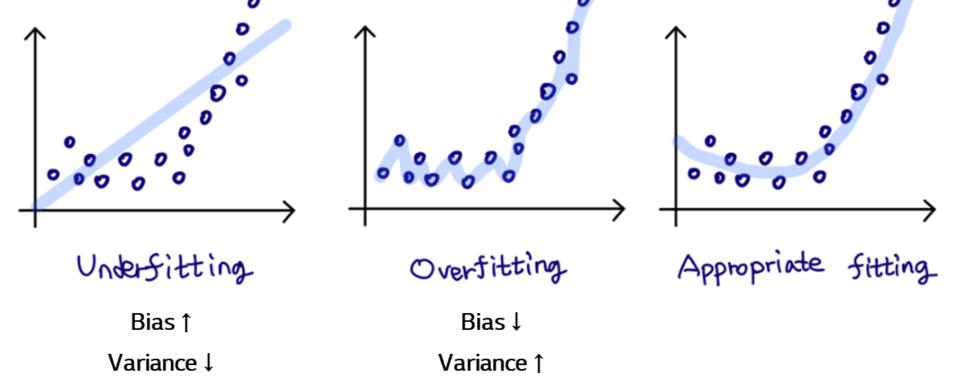
$$Error(X) = \underbrace{Noise(X)}_{Data \ Preprocessing} + \underbrace{Bias(X)}_{Model \ Complexity} + \underbrace{Variance(X)}_{Model \ Complexity}$$



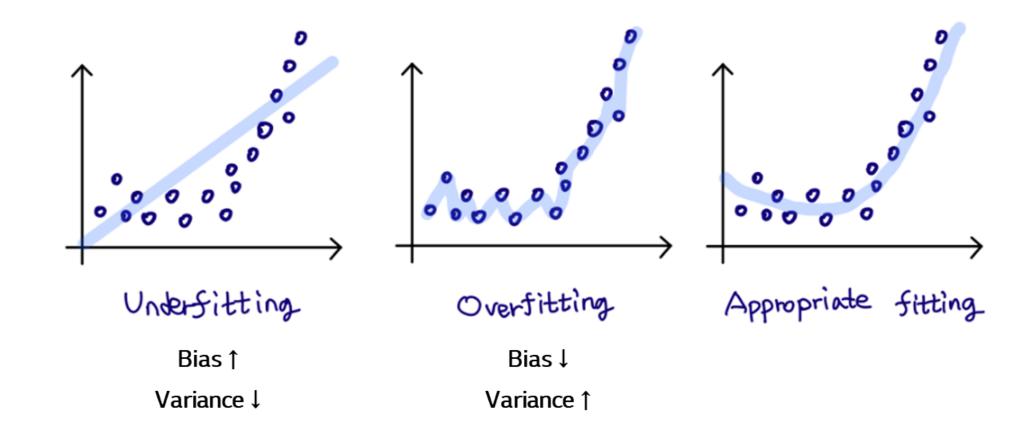


- Train Data vs Test Data
 - Bias와 Variance의 Trade-Off 관계

Error(X) =
$$Noise(X)$$
 + $Noise(X)$ + $Noise(X)$ + $Nodel Complexity \bigcap Model Complexity \b$

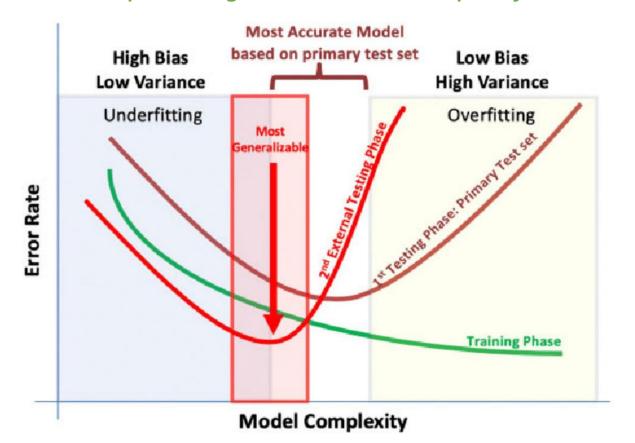


- Underfitting
 - 학습 데이터 내의 모든 정보를 고려하지 못하고 있음 (High Bias)
 - 검증 데이터에 대해 모델의 형태는 크게 변하지 않음 (Low Variance)
- Overfitting
 - 학습 데이터 내의 정보를 잘 설명하고 있음(Low Bias)
 - 검증 데이터에 대해 완전히 다른 형태로 변하게 되고, Generality를 잃게 됨 (High Variance)



- Train Data vs Test Data
 - Bias와 Variance의 Trade-Off 관계

$$Error(X) = \underbrace{Noise(X)}_{Data Preprocessing} + \underbrace{Bias(X)}_{Model Complexity} + \underbrace{Variance(X)}_{Model Complexity}$$



- Train Data vs Test Data
 - Bias와 Variance의 Trade-Off 관계





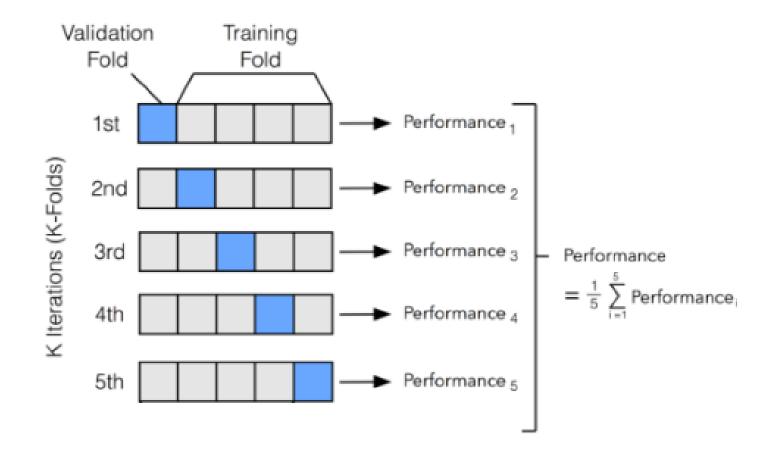
그래서 Overfitting 나쁜거야 ???

원인분석 : Overfitting Is Okay 예측문제 : Overfitting is not Okay

상황에 알맞게 진행

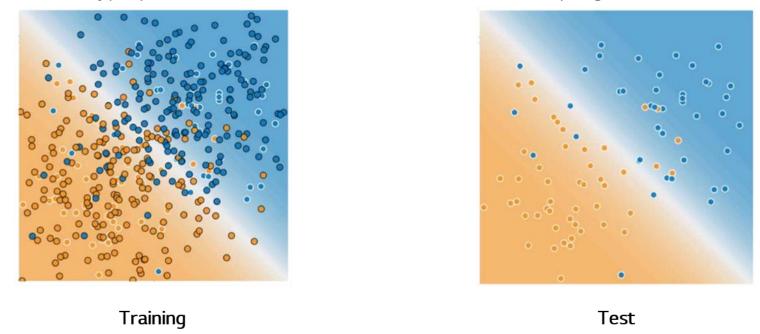
K-Fold Cross Validation

- K-Fold Cross Validation
 - Bias와 Variance의 Trade-Off 관계에서 최적의 Loss 값을 찾기 위함
 - 전체 데이터에 대해 검증할 수 있는 기법
 - Data Size가 크지 않을 때 사용하는 기법
 - Model의 Hyperparameter가 많지 않을 때 사용하는 기법
 - Hyperparameter는 Model의 Complexity를 조절할 수 있는 변수
 - 적게는 1개에서 많게는 10개 이상인 경우가 존재함



Model Validation

• 현실적인 "Big Data" + "# of Hyperparameter"이 많은 Model에서는 Random Sampling

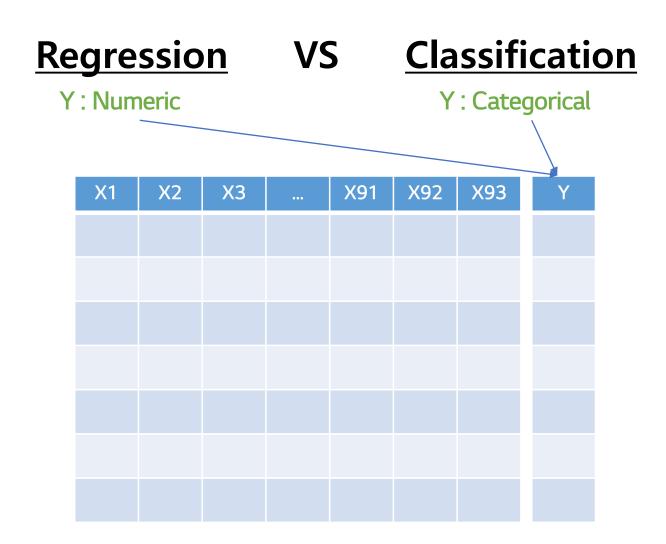


• Time Series Data의 경우 Time으로 Sorting 한 후 시간대로 잘라서 검증함



Loss Function

- 모든 Model(Algorithm)은 Loss Function을 가지고 있음
 - 크게는 Regression, Classification



Loss Function

Regression Loss Function

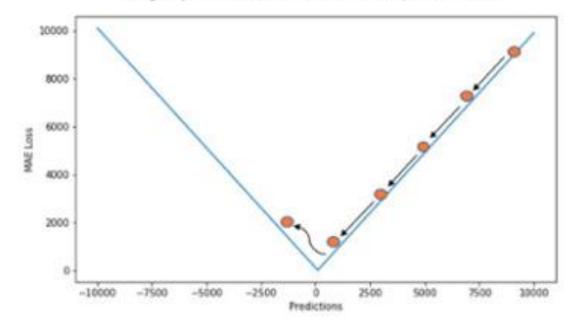
미분 불가능

$$MAE = \frac{1}{N} \sum_{i=1}^{n} |\hat{y_i} - y_i|$$

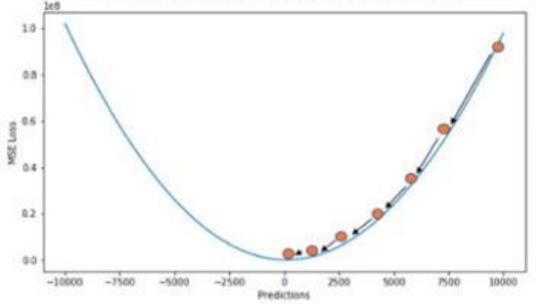
미분 가능

$$\mathit{MSE} = \frac{1}{N} \sum_{i=1}^{n} (\hat{y_i} - y_i)^2 \qquad \mathit{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^{n} (\hat{y_i} - y_i)^2}$$



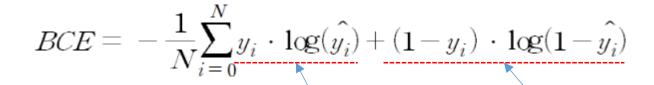


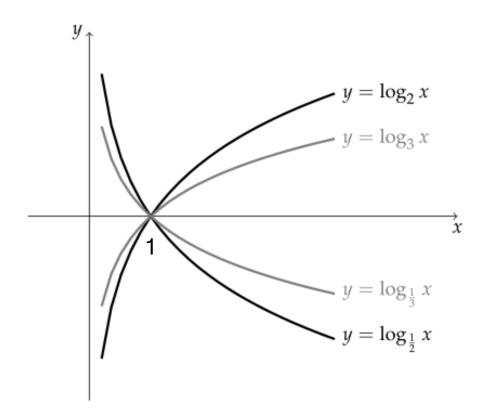


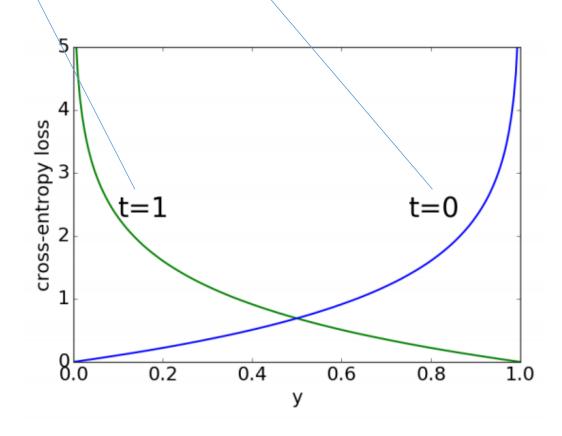


Loss Function

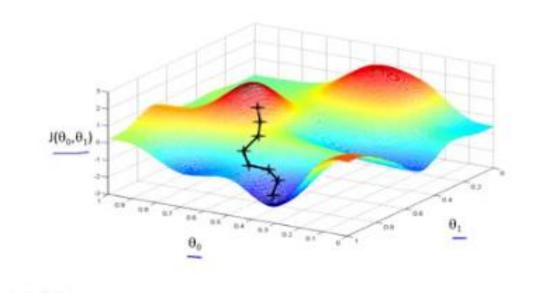
- Classification Loss Function
 - 예측 값을 확률로 뱉음







- Gradient Descent 경사하강법
 - Non-convex 경우 Gradient Descent를 활용하여 해(Loss가 가장 낮은)를 찾아 감
 - 대부분의 non-linear regression 문제는 closed form solution이 존재하지 않음
 - Closed form solution이 존재해도 수많은 parameter가 있을때 GD로 해결하는 것이 효율적



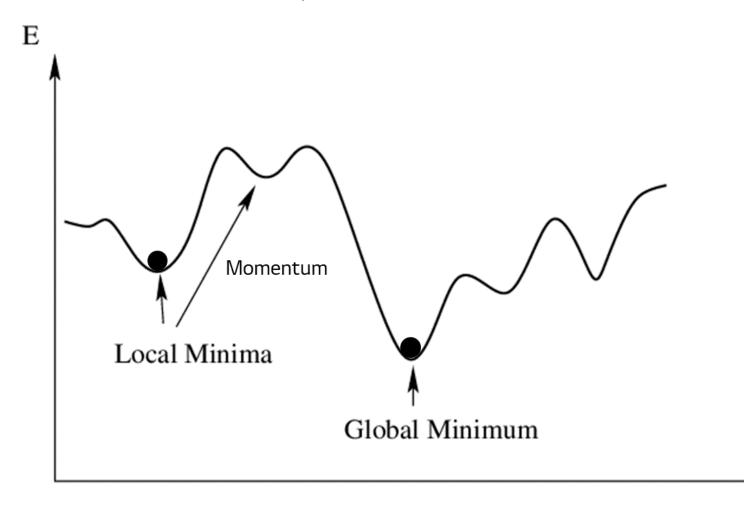
Have some function $J(\theta_0,\theta_1)$ Want $\min_{\theta_0,\theta_1} J(\theta_0,\theta_1)$

Outline:

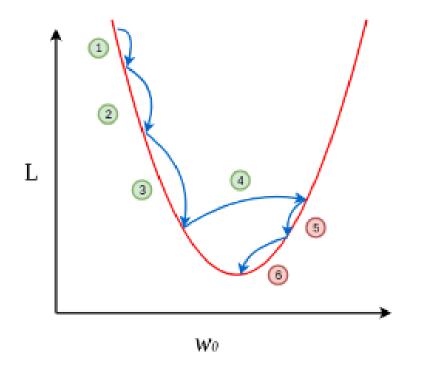
- Start with some θ_0, θ_1
- Keep changing θ_0, θ_1 to reduce $J(\theta_0, \theta_1)$ until we hopefully end up at a minimum

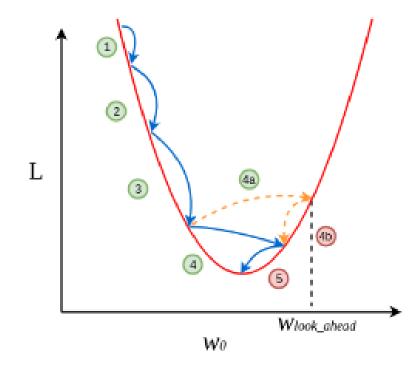
Andrew R

- Gradient Descent 경사하강법
 - Non-convex 경우 Gradient Descent를 활용하여 해(Loss가 가장 낮은)를 찾아 감
 - 대부분의 non-linear regression 문제는 closed form solution이 존재하지 않음
 - Closed form solution이 존재해도 수많은 parameter가 있을때 GD로 해결하는 것이 효율적



- Gradient Descent 경사하강법
 - Non-convex 경우 Gradient Descent를 활용하여 해(Loss가 가장 낮은)를 찾아 감
 - 대부분의 non-linear regression 문제는 closed form solution이 존재하지 않음
 - Closed form solution이 존재해도 수많은 parameter가 있을때 GD로 해결하는 것이 효율적





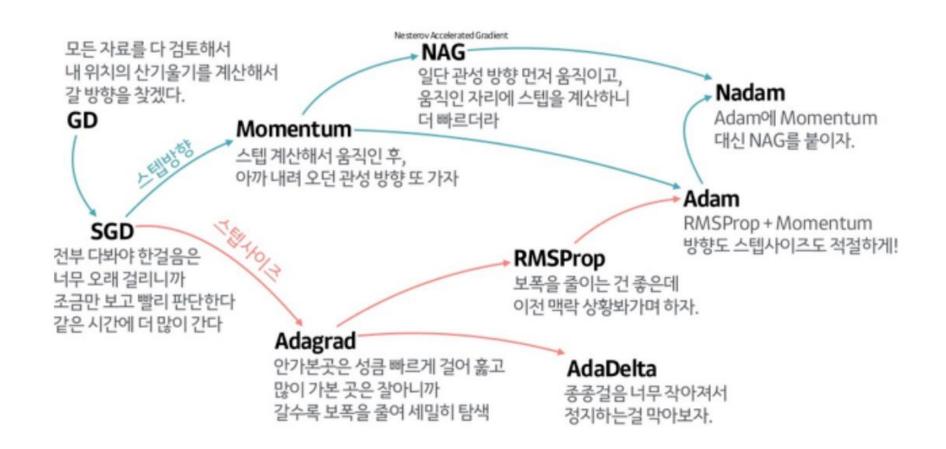
(a) Momentum-Based Gradient Descent

(b) Nesterov Accelerated Gradient Descent

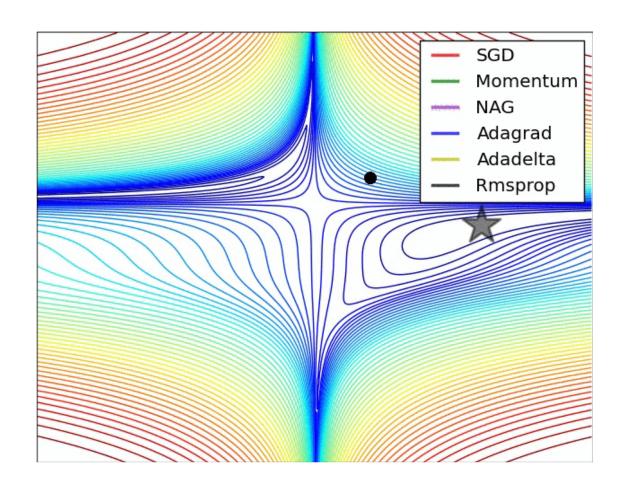
$$\bigcirc \Longrightarrow \frac{\partial L}{\partial w_0} = \frac{Negative(-)}{Positive(+)}$$

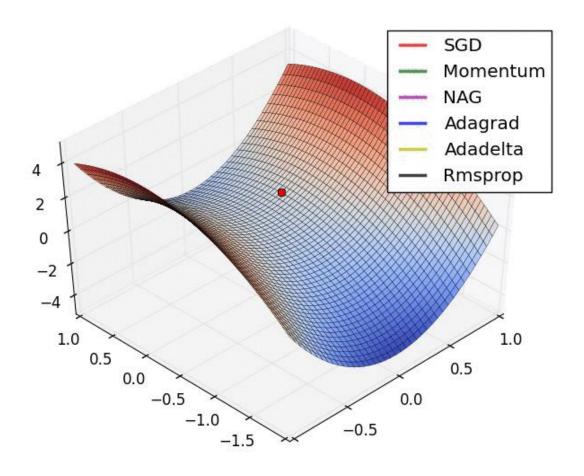
$$\bigcirc \Longrightarrow \frac{\partial L}{\partial w_0} = \frac{Negative(-)}{Negative(-)}$$

- Gradient Descent 경사하강법
 - 종류



- Gradient Descent 경사하강법
 - Non-convex 경우 Gradient Descent를 활용하여 해(Loss가 가장 낮은)를 찾아 감
 - Global Optimal을 보장할 수 없음





Regression VS Classification

Y: Numeric

Y: Categorical

더 어려운 문제는?

eXplainable 한 건?

Q & A