Regression Problem

Data Scientist 안건이

목차

Loss Function Remind

Mathematical Expression

• 지표 해석

• Ridge, LASSO, ElasticNet

• 데이터 실습

Loss Function

Regression Loss Function

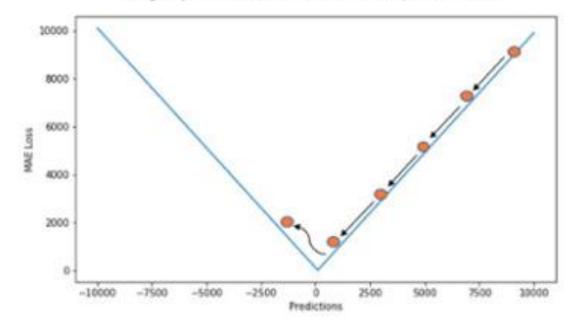
미분 불가능

$$MAE = \frac{1}{N} \sum_{i=1}^{n} |\hat{y_i} - y_i|$$

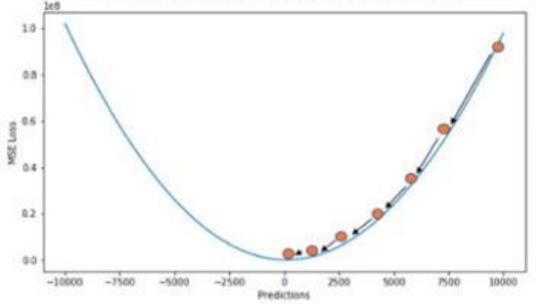
미분 가능

$$\mathit{MSE} = \frac{1}{N} \sum_{i=1}^{n} (\hat{y_i} - y_i)^2 \qquad \mathit{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^{n} (\hat{y_i} - y_i)^2}$$










Regression VS Classification Y: Numeric Y: Categorical

더 어려운 문제는?

eXplainable 한 건 ?

Why Regression?

Linear Regression – 프랜시스 골턴







Francis Galton (1822~1911)

Linear Regression

- 장점
 - Model이 간단하기 때문에 모델 학습 시간이 짧음
 - 선형성 데이터에 적합함
 - 해석력이 가장 좋음
- 단점
 - 복잡한 데이터에 적합하지 않음
 - 비선형성 데이터에 취약함







선형


비선형

Linear Regression






• Linear Regression



Linear Regression



Multi-Linear Regression


$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$


$$E(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Simple & Multi-Linear Regression

$$\varepsilon_i = y_i - E(y_i) = y_i - (\beta_0 + \beta_1 x_i) = y_i - \beta_0 - \beta_1 x_i$$

$$Q(\beta_0, \beta_1) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$





Simple & Multi-Linear Regression Estimation

$$Q(\beta_0, \beta_1) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

$$Minimize Q(\beta_0, \beta_1) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial Q(\beta_0, \beta_1)}{\partial \beta_0} = -2\sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial Q(\beta_0, \beta_1)}{\partial \beta_0} = -2\sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) x_i = 0$$

$$\hat{\beta}_0 = \overline{Y} - \hat{\beta}_1 \overline{X},$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \overline{X})(Y_i - \overline{Y})}{\sum_{i=1}^n (X_i - \overline{X})^2}$$

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$


- Simple & Multi-Linear Regression Estimation
 - β 검증
 - β 에 대한 P-Value가 낮으면 기울기가 0이 아닌것으로 됨
 - 통상적으로 P-value가 0.05이하면 의미 있다고 판단함
 - 즉 *H*_0 은 기각 되며 *H*_1 이 채택 됨

$$H_0: \beta_1 = 0 \text{ vs. } H_1: \beta_1 \neq 0$$

$$t^* = \frac{\hat{\beta}_1 - 0}{sd\{\hat{\beta}_1\}}$$

If
$$|t^*| > t_{\alpha/2,n-2}$$
, we reject H_0

- Simple & Multi-Linear Regression Estimation
 - 회귀모델의 정성적 적합도 판단
 - R^2 은 평균으로 예측한 것에 대비 분산을 얼마나 축소 시켰는지에 대한 판단
 - 보통은 아래의 수식과 달리 Correlation $(y, \hat{y})^2$ 으로 표현함
 - 과연 R^2 가 어느 정도 수치일 때 쓸만한 모델일까?



 $Y_i - \overline{Y}$ (총편차)

X

 X_i

- Simple & Multi-Linear Regression Estimation
 - 회귀모델의 정량적 적합도 판단

성능지표 1: 평균오차

- 실제 값에 비해 과대/과소 추정 여부를 판단
- 부호로 인해 잘못된 결론을 내릴 위험이 있음

Average error =
$$\frac{1}{n} \sum_{i=1}^{n} (y - y')$$
$$= 0.342$$

Age	Actual Weight(y)	Predicted Weight(y')
1	5.6	6.0
2	6.9	6.4
3	10.4	10.9
4	13.7	12.4
5	17.4	15.6
6	20.7	21.5
7	23.5	23.0

- Simple & Multi-Linear Regression Estimation
 - 회귀모델의 정량적 적합도 판단

성능지표 2: 평균 절대 오차(Mean absolute error; MAE)

실제 값과 예측 값 사이의 절대적인
 오차의 평균을 이용

$$MAE = \frac{1}{n} \sum_{i=1}^{n} |y - y'|$$

= 0.829

Age	Actual Weight(y)	Predicted Weight(y')
1	5.6	6.0
2	6.9	6.4
3	10.4	10.9
4	13.7	12.4
5	17.4	15.6
6	20.7	21.5
7	23.5	23.0

- Simple & Multi-Linear Regression Estimation
 - 회귀모델의 정량적 적합도 판단

성능지표 3: Mean absolute percentage error (MAPE)

- 실제값 대비 얼마나 예측 값이 차이 가 있는지를 %로 표현
- 상대적인 오차를 추정하는데 주로 사용

$$MAPE = 100\% \times \frac{1}{n} \sum_{i=1}^{n} \frac{|y - y'|}{|y|}$$
$$= 6.43\%$$

Age	Actual Weight(y)	Predicted Weight(y')
I	5.6	6.0
2	6.9	6.4
3	10.4	10.9
4	13.7	12.4
5	17.4	15.6
6	20.7	21.5
7	23.5	23.0

- Simple & Multi-Linear Regression Estimation
 - 회귀모델의 정량적 적합도 판단

성능지표 4 & 5: (Root) Mean squared error ((R)MSE)

■ 부호의 영향을 제거하기 위해 절대 값이 아닌 제곱을 취한 지표

$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y - y')^{2}$$

$$= 0.926$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y - y')^{2}}$$

$$= 0.962$$

Age	Actual Weight(y)	Predicted Weight(y')
I	5.6	6.0
2	6.9	6.4
3	10.4	10.9
4	13.7	12.4
5	17.4	15.6
6	20.7	21.5
7	23.5	23.0

Q & A